

Київський національний університет імені Тараса Шевченка

Факультет комп'ютерних наук та кібернетики

ЗВІТ

з лабораторної роботи №1

з дисципліни «Навчання з підкріпленням»

на тему «Ітерація за цінністю та ітерація

за стратегією в задачі MountainCar»

Студента 2 курсу магістратури

групи ММШІ-2

Самуся Дем'яна Михайловича

Київ 2026

1. Мета роботи

Розв'язати задачу керування MountainCar двома методами динамічного програмування: ітерацією за цінністю (далі VI, value iteration) та ітерацією за стратегією (далі PI, policy iteration). Обидва методи застосовано до однієї й тієї самої дискретної моделі середовища. Основну увагу приділено тому, чим відрізняється шлях методів до розв'язку: як змінюється стратегія від ітерації до ітерації, скільки обчислень і часу потребує кожен метод і чому підсумкові стратегії, оптимальні в моделі, поведуться в реальному середовищі по-різному.

2. Постановка задачі

Використано середовище MountainCar-v0 з бібліотеки Gymnasium. Автомобіль стоїть у долині між двома пагорбами, і двигун надто слабкий, щоб виїхати на правий пагорб з місця. Щоб досягти прапорця, автомобіль має розгойдатися: спершу заїхати на лівий схил і набрати швидкість на спуску. Параметри середовища наведено в табл. 1.

Елемент	Значення
стан	положення $x \in [-1.2; 0.6]$ і швидкість $v \in [-0.07; 0.07]$
дії	0 – штовхати ліворуч, 1 – не штовхати, 2 – штовхати праворуч
динаміка	$v' = v + (a - 1) \cdot 0.001 - \cos(3x) \cdot 0.0025$, $x' = x + v'$; біля лівої стінки швидкість обнуляється
ціль	$x \geq 0.5$ і $v \geq 0$
винагорода	-1 за кожен крок до досягнення цілі
обмеження епізоду	200 кроків
початковий стан	x рівномірно з $[-0.6; -0.4]$, $v = 0$

Таблиця 1. Середовище MountainCar-v0

Динаміка середовища детермінована і відома, тому оптимальну стратегію можна знайти плануванням без взаємодії із середовищем. Неперервний простір станів дискретизовано сіткою 200×200 (крок 0,0090 за положенням і 0,0007 за швидкістю), тобто 40 000 дискретних станів, з яких 1 200 належать цілі. Наступний стан обчислюється точною формулою динаміки з центру клітинки і округлюється до найближчої клітинки сітки. Модель переходів ($40\,000 \times 3 = 120\,000$ пар «стан – дія») обчислюється один раз за 0,43 с і є спільною для обох методів. Коефіцієнт дисконтування $\gamma = 0.99$.

Оскільки модель детермінована, а винагорода стала, цінність стану залежить лише від кількості кроків до цілі за оптимальної стратегії: стани з однаковою відстанню до цілі мають однакову цінність. Ця властивість далі пояснює більшість відмінностей між методами.

3. Хід роботи

3.1. Реалізація методів

Код роботи розміщено в репозиторії <https://github.com/Kentoso/rl-labs> (папка lab1).

Обидва методи успадковують спільний клас дискретної моделі, тому сітка, переходи і цінність дії $Q(s, a)$ (винагорода за крок плюс дисконтована цінність наступного стану) у них однакові. Відмінності в стратегії пошуку розв'язку зведено в табл. 2.

Аспект	VI	PI
що зберігається	лише цінності V ; стратегія – жадібна до V	цінності V і явна стратегія π
одна ітерація	один прохід по всіх станах з максимумом за трьома діями	оцінювання π до збіжності + одне жадібне покращення
оцінювання	–	синхронні проходи до $\max V' - V \leq \theta = 10^{-4}$, старт з цінностей попередньої ітерації
початковий стан	$V = 0$ для всіх станів	$V = 0$, π = «не штовхати» всюди
вибір серед рівноцінних дій	перша з максимальним Q , тобто «ліворуч»	дія змінюється лише якщо нова строго краща
критерій зупинки	$\max V' - V < 10^{-4}$	жодна дія не змінилася

Таблиця 2. Відмінності реалізацій

Правило «змінювати дію лише за строгого покращення» в PI необхідне: без нього стратегія могла б нескінченно перемикатися між рівноцінними діями. Як показано в розділі 3.5, саме правила вибору серед рівноцінних дій визначають різницю між підсумковими стратегіями.

Для порівняння обидва методи запущено з однаковими параметрами на Apple M3 Max (Python 3.13, один потік). Час вимірювався лише для кроків

навчання, без побудови моделі і без оцінювальних епізодів. Після кожної ітерації для поточної стратегії додатково обчислювалися: кількість змінених дій і частка станів, з яких стратегія в моделі доводить до цілі.

3.2. Кількість ітерацій і час навчання

Основні показники наведено в табл. 3.

Показник	VI	PI
ітерацій	109	74
проходів оцінювання / покращення	109 / –	4 746 / 74
обчислень $Q(s, a)$, млн	$\approx 12,7$	≈ 199
час навчання, с	3,95	69,4
середній час ітерації, с	0,036	0,94

Таблиця 3. Вартість навчання

PI потребує на третину менше ітерацій, але працює в 17,5 раза довше. Ітерація VI – це один прохід по станах, тоді як ітерація PI містить повне оцінювання стратегії, яке може займати сотні проходів. Відношення часу (17,5) близьке до відношення кількості обчислень Q (≈ 16): час визначається саме кількістю проходів.

Кількість ітерацій VI має точне пояснення. Почавши з $V = 0$, після k ітерацій VI правильно оцінює всі стани, з яких ціль досяжна не більше ніж за k кроків; решта станів мають однакову цінність. Найдовший оптимальний шлях у моделі має 108 кроків, тому на 108-й ітерації всі цінності стають точними, а 109-та ітерація лише підтверджує нульову зміну. Тобто нев'язка VI не спадає поступово до допуску: вона повільно зменшується лише до 0,34 і на 109-й ітерації падає до нуля одним кроком.

Розподіл проходів оцінювання PI за ітераціями наведено на рис. 1 (ліворуч). Він дуже нерівномірний.




Рис. 1. Кількість проходів оцінювання PI за ітераціями (ліворуч) і накопичений час навчання обох методів (праворуч)

Перша ітерація потребує 918 проходів (12,7 с, 18 % усього часу). Початкова стратегія «не штовхати» з більшості станів ніколи не доводить до цілі: автомобіль нескінченно коливається в долині. Цінність таких станів поступово наближається до -100 (сума нескінченної кількості штрафів -1 з дисконтуванням $0,99$), і кожен прохід змінює її лише на 1 % менше, ніж попередній. Щоб зміна стала меншою за $\theta = 10^{-4}$, потрібно близько 916 проходів, що майже точно відповідає спостереженому значенню. Друга така хвиля – на 9-й ітерації (1 058 проходів, 14,4 с): після масової зміни дій на 8-й ітерації частина станів знову потрапила в цикли, що не ведуть до цілі. Перші 10 ітерацій забирають 48 % усього часу PI. Коли всі стани вже доводять до цілі (з 30-ї ітерації), цінності стають точними за скінченну кількість кроків. Завдяки старту з попередніх цінностей останні 40 ітерацій потребують здебільшого 2–4 проходи і займають близько 0,1 с кожна.

Отже, перевага PI в кількості ітерацій не перетворюється на перевагу в часі. У цій задачі кожна стратегія з циклами робить оцінювання дорогим, а $\gamma = 0.99$ близьке до одиниці. найдешевшим є саме VI, який не потребує збіжності оцінювання на проміжних кроках.

3.3. Як змінюється стратегія

На рис. 2 порівняно, як швидко стратегія кожного методу стає робочою (ліворуч) і скільки дій змінює кожна ітерація (праворуч).




Рис. 2. Частка станів, з яких поточна стратегія доводить до цілі в моделі (ліворуч), і кількість змінених дій за ітерацію (праворуч)

PI стає робочою значно раніше. Уже на 8-й ітерації 74 % станів доводять до цілі, на 20-й – 98 %, з 30-ї – усі 100 %. Наступні 44 ітерації лише скорочують шляхи до оптимальних, змінюючи від 54 до 3 дій за ітерацію. VI досягає 100 % лише на 104-й ітерації. Причина – різний механізм поширення інформації. VI просуває інформацію про ціль рівно на один крок за ітерацію. Покращення PI теж одноетапне, але після нього оцінювання поширює нову інформацію вздовж усього ланцюжка поточної стратегії. Тому одне покращення може «підключити» до цілі тисячі станів одразу (до 6 865 змінених дій на 9-й ітерації). У VI за ітерацію змінюється не більше 268 дій.

Еволюцію стратегії VI наведено на рис. 3.




Рис. 3. Еволюція жадібної стратегії VI

На початку всі Q дорівнюють -1 , і правило вибору першої дії дає «ліворуч» у всіх станах. Далі від цілі поширюється фронт «поінформованих» станів: спершу смуга вздовж правого краю з додатною швидкістю (ітерація 20), потім дуга з дією «праворуч» над долиною (ітерація 40). Поза фронтом залишається «ліворуч». Різкий стрибок на 32-й ітерації (з 31 % до 83 % станів, рис. 2) має випадкову природу. Коли фронт сформував дугу «праворуч» для руху праворуч, типова дія «ліворуч» для руху ліворуч разом з нею випадково утворила правильну стратегію розгойдування. Тобто VI отримала робочу стратегію частково завдяки правилу вибору серед рівноцінних дій. Останні ітерації (75–109) доводять до ладу внутрішню область навколо дна долини ($x \approx -0.5$, $v \approx 0$), з якої шлях до цілі найдовший; тому в кінці навчання кількість змінених дій знову зростає (рис. 2, праворуч).

Еволюцію стратегії PI наведено на рис. 4.




Рис. 4. Еволюція стратегії PI

PI починає з «не штовхати» всюди. Перше покращення змінює дії лише у верхній смузі, де автомобіль має достатньо енергії: там «праворуч» веде до цілі, а в решті станів усі дії однаково ведуть у цикл, і через правило строгого покращення дія не змінюється. До 6-ї ітерації смуга «праворуч» лише розширюється. На 8-й ітерації з'являється симетрична область «ліворуч» для від'ємних швидкостей, і стратегія розгойдування стає цілісною: 74 % станів доводять до цілі. Далі «острів» нерухомості в центрі долини, де енергії найменше, поступово стискається і повністю зникає до 30-ї ітерації. Тобто PI, на відміну від VI, буде стратегію не фронтом від цілі, а «зовні всередину» за рівнем енергії автомобіля.

В обох методах підсумкова стратегія має однакову структуру: штовхати в напрямку руху, щоб накопичувати енергію. Межа між «ліворуч» і «праворуч» має форму спіралі навколо дна долини: вона відповідає моменту, коли варто почати гальмувати і розвертатися, щоб наступне розгойдування було ефективнішим.

3.4. Порівняння підсумкових стратегій

Підсумкові стратегії обох методів у моделі рівноцінні: функції цінності збігаються точно. Дії відрізняються в 17 223 станах (43 %), але в кожному з них обидві дії однаково добрі (рис. 5).




Рис. 5. Стани, у яких підсумкові стратегії VI і PI відрізняються

У кожному з цих станів обидві дії мають однакове Q , тобто відмінності зумовлені лише правилами вибору серед рівноцінних дій. Причина в дискретизації. Цінність стану залежить лише від кількості кроків до цілі, тому дві дії рівноцінні, якщо ведуть у клітинки з однаковою відстанню до цілі. Сила двигуна (0,001) лише в 1,4 раза більша за крок сітки за швидкістю (0,0007), тому різні дії часто ведуть у клітинки з однаковою відстанню.

Розподіл дій у підсумкових стратегіях наведено в табл. 4.

Дія	VI	PI
ліворуч	30 176	15 978
не штовхати	3 842	10 663
праворуч	5 982	13 359

Таблиця 4. Розподіл дій у підсумкових стратегіях (кількість станів)

VI у рівноцінних станах завжди обирає «ліворуч», бо ця дія перша. PI зберігає дію, яка була строго кращою на одній з попередніх ітерацій, або початкову «не штовхати». Тому відмінності мають лише три напрями: «ліворуч» у VI замість «не штовхати» у PI (9 846 станів), «ліворуч» замість «праворуч» (4 352) і «не штовхати» замість «праворуч» (3 025). Протилежних випадків немає. 11 269 відмінних станів мають додатну швидкість; у 8 621 з них VI штовхає ліворуч, тобто проти руху, хоча за моделлю це не гірше.

3.5. Якість у реальному середовищі

Обидві стратегії перевірено в неперервному середовищі на 100 однакових початкових станах (seed 0–99). Результати наведено в табл. 5 і на рис. 6.

Показник	VI	PI
середня винагорода	–118,7	–109,3
стандартне відхилення	21,5	16,2
найгірший епізод	–168	–149
найкращий епізод	–88	–89
частка успішних епізодів	100 %	100 %
краща на стартах	17	81

Таблиця 5. Результати в середовищі на 100 початкових станах




Рис. 6. Винагорода VI і PI для кожного з 100 початкових станів; точки над діагоналлю – старти, де PI краща

PI краща на 81 старті з 100 і в середньому приблизно на 9 кроків. Найбільший виграш – на найважчих стартах, де VI потрібно 150–168 кроків, а PI – 133–149. Оскільки цінності методів однакові, ця різниця не означає, що PI «краще навчилася». У моделі обидві стратегії оптимальні. У реальному середовищі вибір серед рівноцінних дій має значення, бо округлення до клітинки сітки приховує відмінності між діями.

Щоб перевірити це, жадібну стратегію з цінностей VI побудовано з різними порядками вибору серед рівноцінних дій (табл. 6).

Пріоритет серед рівноцінних дій	Середня винагорода	Найгірший епізод
ліворуч, не штовхати, праворуч (VI)	-118,7	-168
праворуч, не штовхати, ліворуч	-114,1	-154
не штовхати, праворуч, ліворуч	-131,6	-184
не штовхати, ліворуч, праворуч	-132,9	-184
стратегія PI	-109,3	-149

Таблиця 6. Вплив вибору серед рівноцінних дій (цінності VI, 100 стартів)

За однакових цінностей самий лише порядок вибору змінює середню винагороду від -132,9 до -114,1. Фіксований пріоритет «не штовхати» найгірший, тобто перевага PI пояснюється не тим, що вона частіше не штовхає. У PI рівноцінні стани зберігають дію, яка була строго кращою на проміжних ітераціях, коли стратегія ще була неоптимальною. Ця дія частіше відповідає фізично правильному напрямку (у тому числі «праворуч» замість «ліворуч» при русі праворуч). Жоден фіксований порядок не досягає результату PI.

4. Висновки

Обидва методи знайшли одну й ту саму оптимальну функцію цінності дискретної моделі MountainCar (сітка 200×200 , $\gamma = 0.99$), і їхні стратегії доводять автомобіль до цілі з усіх 100 перевірених початкових станів.

PI потребує менше ітерацій (74 проти 109) і значно раніше отримує роботу стратегію: 100 % станів доводять до цілі вже на 30-й ітерації, у VI – на 104-й. Проте за часом VI у 17,5 разів швидша (3,95 с проти 69,4 с). Кількість ітерацій VI дорівнює довжині найдовшого оптимального шляху плюс одна. Вартість PI визначають стратегії з нескінченними циклами: їх оцінювання збігається дуже повільно і потребує близько 916 проходів. Половину часу PI займають перші 10 ітерацій.

Методи будують стратегію по-різному. VI поширює інформацію фронтом від цілі на один крок за ітерацію, а поза фронтом залишає типову дію «ліворуч», яка випадково допомогла сформуванню розгойдування. PI починає з верхньої смуги станів з високою енергією і стискає «острів» нерухомості в центрі долини. Підсумкова стратегія обох методів – штовхати в напрямку руху зі спіральною межею навколо дна долини.

Підсумкові стратегії відрізняються в 43 % станів, але всі ці відмінності – вибір серед рівноцінних дій. Через дискретизацію рівноцінних дій дуже багато. У реальному середовищі ці відмінності суттєві. РІ краща в середньому приблизно на 9 кроків ($-109,3$ проти $-118,7$), однак це наслідок правила строгого покращення і похибки дискретизації, а не якості оптимізації.