

Київський національний університет імені Тараса Шевченка

Факультет комп'ютерних наук та кібернетики

ЗВІТ

з лабораторної роботи №2

з дисципліни «Навчання з підкріпленням»

на тему «Метод Монте-Карло

в задачі MountainCar»

Студента 2 курсу магістратури

групи ММШІ-2

Самуся Дем'яна Михайловича

Київ 2026

1. Мета роботи

Розв'язати задачу керування MountainCar методом Монте-Карло (далі MC), тобто без моделі середовища: агент навчається лише з епізодів, які сам проходить у середовищі. Основну увагу приділено трьом питанням: чи збігається метод на вихідній винагороді, як на навчання впливає формування винагороди (reward shaping) і чим отримана стратегія та вартість її отримання відрізняються від ітерації за цінністю (VI) та ітерації за стратегією (PI) з лабораторної роботи №1.

2. Постановка задачі

Використано те саме середовище MountainCar-v0, що й у лабораторній роботі №1: стан – положення $x \in [-1.2; 0.6]$ і швидкість $v \in [-0.07; 0.07]$, три дії (штовхати ліворуч, не штовхати, штовхати праворуч), винагорода -1 за кожен крок, ціль $x \geq 0.5$, обмеження епізоду 200 кроків, початкове положення рівномірно з $[-0.6; -0.4]$ при $v = 0$.

Дискретизація також та сама: сітка 200×200 (40 000 станів), неперервний стан округлюється до найближчої клітинки. Перетворення між дискретним і фізичним станом, перелік дій і типи стану перенесено з лабораторної роботи №1 без змін. Модель переходів не використовується. Агент не знає формули динаміки і бачить лише результат `env.step`, тобто наступне неперервне спостереження і винагороду.

3. Хід роботи

3.1. Реалізація методу

Код роботи розміщено в репозиторії <https://github.com/Kentoso/rl-labs> (папка lab2).

Реалізовано керування методом Монте-Карло з усіма відвідуваннями (every-visit MC control) і ε -жадібним дослідженням. Агент зберігає таблицю $Q(s, a)$ для всіх $40\,000 \times 3$ пар «стан – дія», початкові значення нульові. Навчання повторює такий цикл:

1. пройти повний епізод ε -жадібною стратегією, запам'ятовуючи трійки (стан, дія, винагорода);
2. пройти епізод з кінця, накопичуючи дисконтовану винагороду $G \leftarrow r + \gamma G$;

3. для кожного кроку зсунути оцінку до спостереженої винагороди: $Q(s, a) \leftarrow Q(s, a) + \alpha(G - Q(s, a))$;
4. зменшити ε .

Параметри наведено в табл. 1.

Параметр	Значення
кількість епізодів	100 000 (порівняння ваг формування), 200 000 (основний запуск)
крок навчання α	0,1 (сталий)
дисконтування γ	0,95
дослідження ε	від 1,0 лінійно зменшується на $1/(N/2)$ за епізод (N – кількість епізодів), нижня межа 0,1
оцінювання під час навчання	20 разів за навчання, 20 епізодів жадібною стратегією (seed 0–19)

Таблиця 1. Параметри навчання

Класичний алгоритм МС усереднює всі отримані винагороди, тобто використовує крок $\alpha = 1/N(s, a)$. Тут використано сталий крок. Стратегія під час навчання змінюється, тому старі епізоди описують уже іншу стратегію. Сталий α зменшує їхню вагу експоненційно, і оцінка стежить за поточною стратегією. Варіант з усіма відвідуваннями обрано тому, що в MountainCar автомобіль часто повертається в ту саму клітинку, і кожне таке відвідування дає додатковий приклад.

Розклад ε узятो з навчального прикладу Gymnasium. Спад розраховано так, ніби ε доходить до нуля за половину навчання, але нижня межа 0,1 зупиняє його на 45 % навчання: на 45 000-му епізоді зі 100 000 або на 90 000-му з 200 000. Далі агент до кінця навчання робить випадкову дію з імовірністю 10 %.

Усі запуски детерміновані (фіксовані seed середовища і генератора випадкових чисел). Запуск на 100 000 епізодів (≈ 20 млн кроків середовища) триває близько 2 хв на Apple M3 Max, на 200 000 епізодів – близько 3 хв (≈ 180 тис. кроків за секунду).

3.2. Навчання на вихідній винагороді

Спершу метод запущено без змін винагороди на сітках 200×200 і 40×40 . За 100 000 епізодів агент жодного разу не досяг цілі, ні під час навчання, ні під час оцінювання.

Поки агент не досяг цілі, кожен епізод обривається на 200-му кроці, а всі винагороди дорівнюють -1 . Тоді винагорода з кроку t

$$G_t = -\frac{1 - \gamma^{200-t}}{1 - \gamma}$$

залежить лише від того, скільки кроків залишилося до обриву, і зовсім не залежить від стану чи дії. Для перших 140 кроків вона лежить між $-19,1$ і -20 . Отже, оцінки Q не містять інформації про те, яка дія краща: різниця між ними – це шум від моменту відвідування. Без жодного успішного епізоду методу немає з чого навчитися, а випадкові дії без розгойдування до цілі не доводять. За 100 000 епізодів агент відвідав лише 21 % клітинок сітки 200×200 і 35 % клітинок сітки 40×40 – усі в долині навколо стартової області.

3.3. Формування винагороди

Щоб дати агенту сигнал до першого успіху, до винагороди за кожен крок додано два бонуси:

$$r' = -1 + w_v \cdot \frac{|v|}{v_{\max}} + w_x \cdot \min\left(\frac{x - x_{\min}}{x_{\text{goal}} - x_{\min}}, 1\right).$$

Перший доданок заохочує швидкість (тобто накопичення енергії), другий – наближення до цілі. Обидва доданки лежать у межах $[0; w]$. Обмеження $\min(\dots, 1)$ потрібне, бо на останньому кроці автомобіль може проїхати трохи далі за ціль (до 1,06). Сума ваг менша за 1, тому винагорода за кожен крок залишається від'ємною, і нескінченно залишатися в середовищі агенту не вигідно. Агент навчається на змінній винагороді, а всі показники в звіті (винагорода, успішність) обчислено за вихідною винагородою середовища.

3.4. Вплив ваг формування

Щоб з'ясувати, який із двох бонусів важливіший, метод запущено на 100 000 епізодів з чотирма розподілами однієї загальної ваги 0,8 (рис. 1, рис. 2). У табл. 2 до них додано запуск без формування і запуск з вагами $w_v = 0.5$, $w_x = 0.3$ (їхня сума також 0,8).




Рис. 1. Частка успішних епізодів жадібної стратегії для різних розподілів ваг (200×200 , 100 000 епізодів). Два запуски з 0 % на всьому проміжку збігаються




Рис. 2. Підсумкові стратегії для різних розподілів ваг

w_v	w_x	перший успіх у навчанні	успішних навчальних епізодів	відвідано станів	середня винагорода
0	0	—	0	21 %	−200
0,8	0	59 104	32 733	66 %	−135,9
0,6	0,2	67 801	18 848	65 %	−142,7
0,5	0,3	80 456	3 220	63 %	−169,2
0,2	0,6	—	0	27 %	−200
0	0,8	—	0	20 %	−200

Таблиця 2. Вплив ваг формування (200×200 , 100 000 епізодів, оцінювання на 100 стартах)

Що більша частка бонусу за швидкість, то раніше агент досягає цілі і то краща підсумкова стратегія. Найкращий варіант – лише бонус за швидкість ($w_v = 0.8$, $w_x = 0$): 100 % успішних епізодів на 100 стартах і середня винагорода −135,9. Варіанти з переважним бонусом за положення не навчаються взагалі: вони відвідують приблизно стільки ж станів, скільки й запуск без формування,

і їхні карти (рис. 2, праворуч) мають такий самий вигляд – диск навколо дна долини.

Щоб розгойдатися, автомобіль має спершу заїхати ліворуч, тобто тимчасово віддалитися від цілі. Бонус за положення за це штрафує, і з $\gamma = 0.95$ (горизонт близько 20 кроків) агент не бачить, що відступ окупиться пізніше. Бонус за швидкість, навпаки, винагороджує сам процес розгойдування незалежно від напрямку. Це інтерпретація за картами стратегій, окремо вона не перевірялася.

В усіх запусках, що навчилися, перший успішний епізод настає вже після того, як ϵ досяг нижньої межі (45 000-й епізод). Тобто ціль досягає не випадкове блукання з великим ϵ , а майже жадібна стратегія, яка завдяки бонусу за швидкість розгойдує автомобіль усе сильніше.

3.5. Основний запуск

Для основного запуску обрано найкращі ваги ($w_v = 0.8$, $w_x = 0$) і вдвічі більше епізодів, 200 000, щоб побачити, чи стратегія збігається. Криві навчання наведено на рис. 3.




Рис. 3. Основний запуск (200×200 , $w_v = 0.8$, $w_x = 0$, 200 000 епізодів): винагорода навчальних епізодів (ковзне середнє за 500 епізодів), середня винагорода жадібної стратегії, розклад ϵ і середня похибка $|G - Q|$ за епізод

Розклад ϵ розтягується разом з кількістю епізодів, тому нижньої межі ϵ досягає на 90 000-му епізоді. Перший успішний навчальний епізод – 91 058-й, тобто знову одразу після цього. Далі навчання йде швидко: на 100 000-му епізоді жадібна стратегія досягає цілі на 18 з 20 стартів (середня винагорода –162,8), з 110 000-го – на всіх 20. З 120 000-го епізоду середня винагорода жадібної стратегії коливається між –134 і –141, а похибка $|G - Q|$ після різкого спаду біля 100 000-го епізоду майже не змінюється. Винагорода навчальних епізодів зростає повільніше і в кінці становить близько –140: у ній є випадкові дії з $\epsilon = 0.1$.

Отже, жадібна стратегія збіглася приблизно за 30 000 епізодів після того, як ϵ досяг нижньої межі, і останні 80 000 епізодів її майже не змінили. Порівняно із запуском на 100 000 епізодів з тими самими вагами середня винагорода на 100 стартах покращилася мало (–133,8 проти –135,9), але найгірший епізод став значно кращим (–145 проти –176).

Як змінюється жадібна стратегія, показано на рис. 4.




Рис. 4. Еволюція жадібної стратегії основного запуску

На початку всі Q нульові, і жадібний вибір дає першу дію, «ліворуч», у всіх станах. У станах, які агент ніколи не відвідав, ця дія так і залишається, тому суцільна синя область по краях карт – це не навчена дія, а невідвідані клітинки. Відвідана область росте від стартових станів назовні: невеликий диск навколо

дна долини на 40 000-му епізоді, широкі витки до $x \approx 0.25$ на 80 000-му. На 120 000-му епізоді витки дістаються цілі, і з'являється смуга «праворуч», що веде до неї. Усередині відвіданої області структура правильна: «праворуч» при русі праворуч (верхня половина), «ліворуч» при русі ліворуч (нижня половина) і біля дна долини. Між 120 000 і 200 000 епізодами змінюється переважно смуга перед ціллю, яка стає чіткішою. Решта карти залишається «зернистою»: сусідні клітинки часто мають різні дії, бо кожна з них оцінюється за невеликою кількістю зашумлених епізодів.

3.6. Порівняння з ітерацією за цінністю та за стратегією

VI і PI з лабораторної роботи №1 і MC з цієї роботи розв'язують ту саму задачу на тій самій сітці 200×200 , але принципово різними способами. VI і PI – це планування: вони знають модель переходів і обчислюють цінність кожного стану. MC – це навчання з досвіду: модель невідома, і оцінки Q будуються лише за пройденими епізодами. Порівняння наведено в табл. 3. Для MC наведено запуски з вагами $w_v = 0.8$, $w_x = 0$ на 100 000 і 200 000 (основний) епізодів. Усі стратегії перевірено на тих самих 100 стартах (seed 0–99) за вихідною винагородою.

Показник	VI	PI	МС, 100 тис. епізодів	МС, 200 тис. епізодів
потрібна модель	так	так	ні	ні
дані для навчання	120 000 переходів моделі	120 000 переходів моделі	18,6 млн кроків середовища	34,7 млн кроків середовища
час навчання	3,95 с (+0,43 с модель)	69,4 с (+0,43 с модель)	≈ 106 с	≈ 191 с
винагорода, на якій навчався	вихідна	вихідна	змінена	змінена
γ	0,99	0,99	0,95	0,95
стани з навченою дією	100 %	100 %	66 %	67 %
частка успішних епізодів	100 %	100 %	100 %	100 %
середня винагорода	-118,7	-109,3	-135,9	-133,8
стандартне відхилення	21,5	16,2	13,5	13,6
найгірший / найкращий епізод	-168 / -88	-149 / -89	-176 / -109	-145 / -108

Таблиця 3. Порівняння МС з VI і PI (сітка 200 × 200)

Вартість. VI отримує оптимальну стратегію за 4 с, МС – за близько 3 хв і 35 млн кроків середовища. Модель дозволяє VI і PI обчислити кожен перехід один раз, а МС мусить багато разів проїхати траєкторію, щоб оцінити її винагороду, і перші 91 000 епізодів основного запуску взагалі не досягають цілі. МС не потрібна модель. Якщо формули динаміки невідомі, VI і PI неможливо застосувати, а МС – можна. Крім того, вартість VI і PI зростає з кількістю станів моделі, тоді як МС витрачає приклади лише на ті стани, які реально відвідує агент.

Як поширюється інформація. У трьох методах стратегія будується в різних напрямках. VI поширює інформацію фронтом від цілі на один крок за ітерацію. PI стискає «острів» нерухомості від станів з високою енергією до дна долини. МС, навпаки, росте від стартових станів назовні (рис. 4): він знає лише те, куди вже доїхав. Через це в МС довго немає жодного сигналу про ціль, і без формування винагороди він не збігається взагалі (розділ 3.2). VI і PI такої проблеми не мають: модель одразу показує, які стани є цільовими.

Підсумкові стратегії. Карти стратегій наведено на рис. 5.




Рис. 5. Підсумкові стратегії VI, PI і MC (основний запуск); лінія – траєкторія MC зі старту seed 1234, точка – початковий стан

Структура стратегії MC у відвіданій області та сама, що й у VI і PI: штовхати в напрямку руху, щоб накопичувати енергію. Проте в MC немає чітких меж між областями: карта зерниста, а поза відвіданою областю залишається початкова дія «ліворуч». Траєкторія зі старту seed 1234 досягає цілі за 145 кроків, розгойдуючись кількома обертами навколо дна долини.

Щоб оцінити, наскільки дії MC правильні, їх перевірено за цінностями VI: дія MC вважається оптимальною, якщо її Q за VI дорівнює максимальному (рис. 6).




Рис. 6. Відвідані основним запуском MC стани і правильність його дій за цінностями VI; лінія – траєкторія зі старту seed 1234

У 83,9 % відвіданих станів (22 357 з 26 636) дія МС оптимальна за VI, а вздовж траєкторії seed 1234 – у 89,0 % кроків. Ця оцінка м'яка: як показано в лабораторній роботі №1, через дискретизацію багато станів мають кілька рівноцінних дій, і будь-яка з них зараховується як оптимальна. Неоптимальні дії розкидані по всій відвіданій області, а найбільше їх скупчення – біля дна долини при малій від'ємній швидкості ($x \approx -0.7 \dots -0.5$), через яке проходить перше розгойдування.

Винагорода на кожному старті порівняно з VI наведена на рис. 7.




Рис. 7. Винагорода VI і основного запуску МС для кожного з 100 початкових станів; точки над діагоналлю – старти, де МС краща

VI краща на 58 стартах, МС – на 42. У середньому МС потребує на 15 кроків більше, ніж VI, і на 24 більше, ніж PI. Водночас найгірший епізод МС (–145) кращий, ніж у VI (–168) і PI (–149). Винагороди МС утворюють дві групи: –108...–120 (29 стартів) і –138...–145 (71 старт), а VI дає від –88 до –168 залежно від старту. На стартах, де VI краща за своє середнє, МС виграє лише на 4 з 51, а на решті – на 38 з 49. Тобто МС програє VI на легких стартах і виграє на важких. VI оптимальна лише в дискретній моделі: модель обіцяє 83–102 кроки, а в середовищі через округлення стану VI потребує 88–168, тоді як МС навчався на справжній динаміці. Ймовірно, групи відповідають різній кількості розгойдувань, але окремо це не перевірялося.

Середня різниця з VI і PI має кілька можливих причин, внесок кожної окремо не вимірювався:

- МС навчався на змінній винагороді, оптимальна стратегія для якої не обов'язково збігається з найкоротшим шляхом до цілі;
- $\gamma = 0.95$ дає горизонт близько 20 кроків, тоді як шлях до цілі за стратегією VI триває 88–168 кроків;
- кожен клітинку оцінено за невеликою кількістю зашумлених епізодів, а $\varepsilon = 0.1$ до кінця навчання додає випадкові дії до цих епізодів.

Довше навчання цю різницю майже не зменшило: жадібна стратегія стабілізувалася на рівні близько -135 з 120 000-го епізоду (розділ 3.5).

4. Висновки

Метод Монте-Карло з усіма відвідуваннями, сталим кроком $\alpha = 0.1$ і ε -жадібним дослідженням реалізовано для MountainCar на тій самій дискретній сітці 200×200 , що й VI та PI, але без моделі середовища.

На вихідній винагороді метод не збігається на жодній із сіток: за 100 000 епізодів агент жодного разу не досяг цілі. Поки ціль не досягнута, винагорода з кожного кроку залежить лише від часу до обриву епізоду і не несе інформації про дію, тому навчатися немає з чого.

З формуванням винагороди метод збігається, і найкраще працює лише бонус за швидкість. З переважним бонусом за положення метод не навчається взагалі, як і без формування. В усіх успішних запусках перший успіх настає лише після того, як ε досягає нижньої межі. В основному запуску на 200 000 епізодів жадібна стратегія збігається приблизно за 30 000 епізодів після цього і далі майже не змінюється: вона досягає цілі на всіх 100 перевірених стартах із середньою винагородою $-133,8$.

Порівняно з VI і PI метод Монте-Карло значно дорожчий (≈ 3 хв і 35 млн кроків середовища проти 4 с у VI) і дає гіршу в середньому стратегію ($-133,8$ проти $-118,7$ у VI та $-109,3$ у PI), хоча його найгірший епізод (-145) кращий, ніж у VI і PI. Стратегія МС має ту саму структуру – штовхати в напрямку руху, – але визначена лише у відвіданих 67 % станів і зерниста; у відвіданих станах 83,9 % дій оптимальні за VI. МС не потребує моделі. VI і PI тут виграють, бо модель MountainCar відома і детермінована; у задачі з невідомою динамікою з трьох методів можна застосувати лише МС.